Aprendizado Simbólico e Conexionista Aplicados a Sinais Vitais: Modelagem, Implementação e Resultados com Random Forest e MLP

Felipe dos Reis Garcez[1], **Gabriel Affonso Borges Caballero**[1]

[1]Universidade Tecnológica Federal do Paraná

felipegarcez@alunos.utfpr.edu.br, gabrielaffonso@alunos.utfpr.edu.br

Abstract. *This paper compares two machine learning approaches for assessing the severity of accident victims from three vital signs: a Random Forest, representing the symbolic paradigm, and a Multilayer Perceptron (MLP), representing the connectionist paradigm. Each technique was applied both to regression of a continuous severity index and to classification into four severity classes, with hyperparameters selected by stratified cross-validation. Both approaches performed well, and predicting severity before deriving the class outperformed direct classification for both techniques. The best model, an MLP regressor, reached 0.96 accuracy, 0.94 macro F1 and an RMSE of 2.13. The paper also discusses the ethical and practical implications of using such models in triage.*

Resumo. *Este artigo compara duas abordagens de aprendizado de máquina para avaliar a gravidade de vítimas de acidentes a partir de três sinais vitais: a Random Forest, representante do paradigma simbólico, e a rede neural Perceptron Multicamadas (MLP), representante do paradigma conexionista. Cada técnica foi aplicada à regressão de um índice contínuo de gravidade e à classificação em quatro classes, com hiperparâmetros selecionados por validação cruzada estratificada. As duas abordagens tiveram bom desempenho, e prever a gravidade antes de derivar a classe superou a classificação direta nas duas técnicas. O melhor modelo, uma MLP regressora, alcançou acurácia de 0,96, F1 macro de 0,94 e RMSE de 2,13. O artigo também discute as implicações éticas e práticas do uso desses modelos na triagem.*

1. Introdução

Em cenários de catástrofes naturais, desastres ou grandes acidentes, a triagem rápida de vítimas é determinante para o uso eficiente de recursos de resgate. Este trabalho aborda a reconstituição, por aprendizado de máquina, de um processo de avaliação de gravidade a partir de sinais vitais, cuja fórmula original foi perdida. A tarefa possui duas faces complementares: estimar um valor contínuo de gravidade (um problema de regressão) e classificar cada vítima em uma entre quatro classes de gravidade: crítico, instável, potencialmente estável e estável (um problema de classificação).

O objetivo é comparar duas modelagens de naturezas distintas: a Floresta Aleatória (Random Forest), de base simbólica e apoiada em árvores de decisão, e a rede neural Perceptron Multicamadas (MLP), de base conexionista. Ambas são aplicadas às duas tarefas, permitindo analisar semelhanças, diferenças, vantagens e limites de cada abordagem. O código-fonte está disponível no repositório do projeto[1].

Além da comparação técnica, o trabalho discute os desdobramentos do uso desses modelos em cenários com pessoas reais, considerando aspectos como ética, justiça, confiança no sistema e controle humano.

[1]https://github.com/FelipeReis96/Sistemas-Inteligentes

2. O problema e o conjunto de dados

O conjunto de dados representa um histórico de 1500 vítimas de acidentes, cujos sinais vitais foram avaliados por um corpo médico. Conforme o enunciado, os valores são sintéticos e gerados aleatoriamente dentro de faixas predefinidas. Cada registro traz cinco sinais vitais (as pressões sistólica e diastólica, a qualidade da pressão arterial, ou qPA, o pulso e a frequência respiratória), além de um identificador, um índice contínuo de gravidade e a classe correspondente.

Por determinação do enunciado, as pressões sistólica e diastólica não são usadas como entrada, pois já estão sintetizadas na qPA. O identificador também é descartado. Assim, os atributos de entrada são a qPA, que vai de -10 a 10 (o 0 indica a qualidade máxima, e os extremos, pressão baixa ou alta demais), o pulso, de 0 a 200 batimentos por minuto, e a frequência respiratória, de 0 a 22 respirações por minuto. Os alvos são a gravidade (valor contínuo) e a classe (rótulo de 1 a 4). Apesar do nome, quanto maior a gravidade, mais estável está a vítima: a média é de 16,9 na classe 1 (crítico) e de 81,8 na classe 4 (estável).

A análise exploratória evidenciou três características que orientam a modelagem. Primeiro, o forte desbalanceamento entre as classes: são 234 vítimas críticas (15,6%), 832 instáveis (55,5%), 404 potencialmente estáveis (26,9%) e apenas 30 estáveis (2,0%). Segundo, a relação não linear entre os sinais e a gravidade, em formato de "U invertido": a gravidade é máxima em valores fisiologicamente normais (qPA próxima de 0, pulso entre 60 e 100, respiração entre 12 e 16) e decresce nos extremos, como ilustra a Figura 1. Por isso, a correlação linear de cada atributo com a gravidade é fraca ($-0{,}29$, $-0{,}09$ e $0{,}39$, respectivamente), o que justifica o uso de modelos não lineares. Terceiro, a classe corresponde à gravidade dividida em faixas. Como o enunciado informa que os limites foram perdidos, eles foram reconstituídos com uma árvore de decisão treinada apenas com os dados de treino, tendo a gravidade como única entrada e no máximo quatro folhas. A árvore encontrou os limites 25,00, 50,01 e 75,26 e acertou todas as vítimas de treino: os valores foram arredondados para 25, 50 e 75. Na Figura 1, os pontos de cada classe nunca cruzam esses limites, o que legitima obter a classe por pós-processamento da gravidade prevista pela regressão.

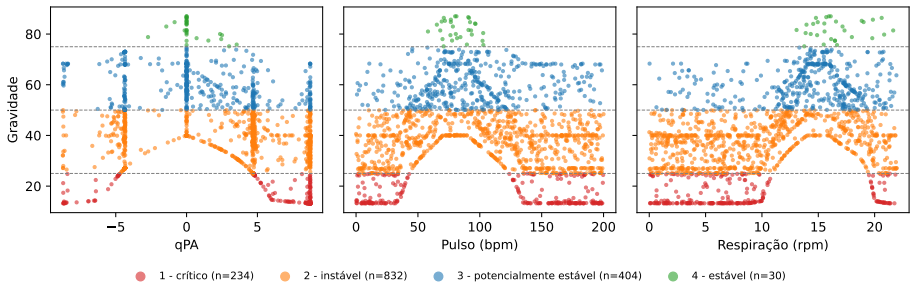


Figura 1. Gravidade em função de cada sinal vital, com as vítimas coloridas por classe. As linhas tracejadas marcam os limites entre as classes.

3. Metodologia

Os experimentos foram implementados em Python, com a biblioteca scikit-learn [Pedregosa et al. 2011] (versão 1.9.1). Todos os sorteios usam a mesma semente, o que torna os resultados reprodutíveis.

3.1. Preparação e divisão dos dados

O conjunto foi dividido em 80% para treino (1200 vítimas) e 20% para teste (300 vítimas), de forma estratificada, isto é, mantendo a proporção de cada classe nos dois subconjuntos. Sem isso,

a classe estável poderia ficar quase ausente do teste. Com a estratificação, são 24 vítimas estáveis no treino e 6 no teste. O conjunto de teste não participa de nenhuma decisão de modelagem e é usado uma única vez, ao final, com a mesma divisão para todos os modelos.

3.2. Tarefas e modelos avaliados

Cada técnica foi aplicada às duas tarefas, resultando em quatro modelos: um classificador e um regressor para cada técnica. Os classificadores preveem a classe diretamente, e os regressores preveem a gravidade, que é convertida em classe pelos limites da Seção 2, um pós-processamento previsto no próprio enunciado. Assim, além de comparar as duas técnicas, é possível comparar a classificação direta com a classificação obtida a partir da gravidade.

3.3. Seleção de hiperparâmetros

A escolha dos hiperparâmetros combinou duas análises. A busca em grade usou, para quase todos os hiperparâmetros, o valor padrão da biblioteca e uma ou duas alternativas plausíveis, como 100 ou 300 árvores e regularização de 10^{-4} (padrão) ou 10^{-2}, mantendo o número de combinações viável. A exceção é a arquitetura da MLP: em vez do padrão de uma camada com 100 neurônios, foram testadas redes menores, mais adequadas a um problema com apenas três entradas. De forma complementar, uma análise de sensibilidade fixou uma configuração base para cada modelo e variou um hiperparâmetro por vez, numa faixa mais ampla, avaliando cada variação por validação cruzada (Apêndice B). Ela mostra o efeito isolado de cada hiperparâmetro e permite verificar se os valores deixados fora da grade eram de fato inferiores.

A busca em grade testou todas as combinações das faixas escolhidas: 64 configurações para o classificador e 16 para o regressor da Random Forest, e 48 para cada modelo MLP (grades completas no Apêndice A). Cada configuração foi avaliada por validação cruzada com cinco partições sobre o conjunto de treino, e sua nota é a média das cinco avaliações. As partições são estratificadas pela classe, geradas uma única vez e compartilhadas pelos quatro modelos, inclusive pelos regressores, cujo alvo contínuo não permitiria a estratificação de outra forma.

Para os classificadores, o critério de escolha foi a medida F1 macro, que dá o mesmo peso às quatro classes. A acurácia não seria adequada aqui: um modelo que nunca previsse a classe estável ainda teria acurácia alta, já que ela representa só 2% dos dados. Para os regressores, o critério foi a raiz do erro quadrático médio (RMSE). Ao final, a melhor configuração de cada modelo foi treinada novamente com todo o conjunto de treino e avaliada no conjunto de teste.

3.4. Métricas de avaliação

Os classificadores foram avaliados por acurácia, precisão, revocação e medida F1, calculadas por classe e pela média macro, e pela matriz de confusão. A revocação da classe crítica recebe destaque na análise, pois deixar de identificar uma vítima crítica é o erro de maior custo nesse cenário. Os regressores foram avaliados pelo RMSE, que está na mesma unidade da gravidade e penaliza mais os erros grandes, pelo erro absoluto médio (MAE) e pelo coeficiente de determinação (R^2). Para eles, também foram calculadas as métricas de classificação sobre a classe obtida pelos limites. Por fim, a importância de cada atributo foi estimada por permutação [Breiman 2001]: embaralha-se um atributo no conjunto de teste e mede-se a queda de desempenho do modelo. Esse método se aplica da mesma forma às duas técnicas, o que permite compará-las.

3.5. Modelagem com Random Forest

Uma floresta aleatória [Breiman 2001] é um conjunto de árvores de decisão em que cada árvore é treinada com uma amostra diferente dos dados, sorteada com reposição (*bootstrap*), e, a cada divisão, considera apenas um subconjunto sorteado dos atributos. Na classificação, a previsão final

é a classe mais votada entre as árvores, e na regressão, é a média das previsões. Como cada árvore é exposta a informações diferentes, seus erros tendem a se compensar na agregação, o que reduz a variância em relação a uma árvore isolada.

O tipo de árvore utilizado foi o CART, implementado pelo scikit-learn. Ele trabalha diretamente com atributos contínuos, fazendo divisões binárias com limiares do tipo "pulso ≤ 147?", e também resolve problemas de regressão, escolhendo as divisões que mais reduzem a variância da gravidade em cada nó. O ID3 exigiria discretizar os atributos, com perda de informação, e o C4.5 não está disponível na biblioteca. Ainda assim, o critério de divisão por entropia, o mesmo ganho de informação usado pelo ID3 e pelo C4.5, foi incluído na busca como alternativa ao índice de Gini, padrão do CART. Como a árvore compara um atributo de cada vez com um limiar, não há normalização nesta modelagem.

A grade variou o número de árvores (100 ou 300), a profundidade máxima (10 ou ilimitada), o número mínimo de exemplos para dividir um nó (2 ou 5) e o número de atributos considerados em cada divisão (1 ou todos os 3). O valor padrão do classificador, a raiz quadrada do número de atributos, equivale a 1 neste problema. No classificador, também variaram o critério de divisão e o peso das classes. A opção balanceada atribui a cada classe um peso inversamente proporcional à sua frequência, de modo que errar uma vítima da classe estável custe mais durante o treino, uma forma direta de compensar o desbalanceamento.

3.6. Modelagem com Rede Neural MLP

A segunda modelagem usa redes neurais do tipo Perceptron Multicamadas (MLP), que aproximam funções não lineares por meio de camadas de neurônios totalmente conectados, com as classes `MLPClassifier` e `MLPRegressor` do scikit-learn.

Cada rede possui uma camada de entrada com três neurônios, uma ou mais camadas ocultas e uma camada de saída. Na classificação, a saída tem quatro neurônios com ativação *softmax*, retornando a classe de maior probabilidade, enquanto na regressão, a saída é um único neurônio linear. No scikit-learn, essa camada de saída e a função de perda são definidas automaticamente conforme a tarefa (entropia cruzada na classificação e erro quadrático na regressão). Os pesos são ajustados por retropropagação do erro [Rumelhart et al. 1986]. Como a MLP é sensível à escala das entradas, e estas apresentam faixas muito distintas (pulso em $[0, 200]$ e qPA em $[-10, 10]$), aplicou-se padronização (`StandardScaler`) antes da rede. A padronização foi encapsulada em um *pipeline* junto ao modelo, de modo a ser reajustada apenas com os dados de treino de cada partição da validação cruzada.

A grade variou a arquitetura das camadas ocultas (uma camada de 16 neurônios ou duas camadas, de 32 e 16 ou de 64 e 32), a função de ativação (*relu* ou *tanh*), a regularização L2 ($\alpha = 10^{-4}$ ou 10^{-2}) e o otimizador: *adam*, que usa uma taxa de aprendizado fixa, testada em 0,1, 0,01 e 0,001, ou L-BFGS, que não depende desse parâmetro. Por isso, a busca foi organizada em duas grades, uma por otimizador, totalizando 48 configurações por tarefa. O número máximo de iterações foi limitado a 1000. Com o L-BFGS, a rede atinge esse limite sem satisfazer o critério de convergência da biblioteca, mas aumentar o limite para 3000 não melhorou o desempenho na validação cruzada, indicando que iterações adicionais apenas ajustam a rede ainda mais ao treino. Por fim, ao contrário da Random Forest, a MLP do scikit-learn não oferece pesos por classe, então o desbalanceamento é tratado apenas pela estratificação dos dados e pelo uso do F1 macro como critério de escolha.

3.7. Requisitos funcionais e não funcionais

A Tabela 1 resume os requisitos das duas modelagens.

Tabela 1. Requisitos funcionais e não funcionais das duas modelagens.

	Random Forest	**MLP**
Requisitos funcionais		
Entradas	qPA, pulso e respiração (valores reais) nas duas modelagens	
Saídas	classe por votação das árvores, gravidade pela média das árvores	classe por softmax (4 neurônios), gravidade por 1 neurônio linear
Pré-processamento	nenhum	padronização ajustada apenas no treino
Desbalanceamento	pesos por classe	sem mecanismo nativo na biblioteca
Busca de hiperparâmetros	64 (classificação) e 16 (regressão) configurações	48 configurações por tarefa
Requisitos não funcionais		
Interpretabilidade	intermediária: cada árvore é um conjunto de regras legíveis, e a floresta permite inspecionar caminhos e importâncias	baixa: o conhecimento fica distribuído nos pesos da rede
Sensibilidade à escala	nenhuma	alta
Sensibilidade à aleatoriedade	baixa: a agregação de muitas árvores estabiliza o resultado	maior: depende da inicialização dos pesos e da convergência
Custo de treino	moderado, paralelizável entre as árvores	maior, iterativo, com limite de iterações
Reprodutibilidade	garantida pela semente fixa nas duas modelagens	

4. Resultados

4.1. Análise de sensibilidade

A análise de sensibilidade, detalhada no Apêndice B, mostra o efeito isolado de cada hiperparâmetro e permite avaliar as grades usadas na busca. Na Random Forest, árvores rasas (3 ou 5 níveis) e um número mínimo alto de exemplos por divisão prejudicaram os dois modelos, e na regressão usar os três atributos em cada divisão reduziu o RMSE de 4,20 para 2,83. Os valores fora da grade tiveram desempenho inferior ou praticamente igual ao dos testados, como 500 árvores em vez de 300 ou profundidade de 20 níveis em vez de ilimitada. Na MLP, a ativação logística, o otimizador SGD e a taxa de aprendizado de 10^{-4} mostraram-se inadequados, o L-BFGS superou o Adam nas duas tarefas e a regressão exigiu redes maiores que a classificação. Houve duas exceções: a rede com três camadas e a regularização de 10^{-1} ficaram fora da grade e foram as melhores na análise, mas com vantagem dentro da variação entre as partições.

4.2. Configurações selecionadas

A Tabela 2 apresenta a configuração escolhida pela busca em grade para cada modelo. As duas redes escolheram o L-BFGS, a ativação tangente hiperbólica e a regularização mais forte, e a rede de regressão ficou maior que a de classificação, o que é coerente com a análise de sensibilidade. As duas florestas escolheram árvores de profundidade ilimitada e o uso dos três atributos em cada divisão.

Tabela 2. Configuração selecionada para cada modelo e desempenho na validação cruzada (média $\pm$ desvio padrão nas cinco partições).

Modelo	**Configuração selecionada**	**Validação cruzada**
RF classificador	100 árvores, entropia, profundidade ilimitada, mínimo de 2 exemplos para divisão, 3 atributos por divisão, pesos balanceados	F1 = 0,881 $\pm$ 0,038
RF regressor	300 árvores, profundidade ilimitada, mínimo de 2 exemplos para divisão, 3 atributos por divisão	RMSE = 2,79 $\pm$ 0,47
MLP classificador	1 camada oculta (16 neurônios), tanh, L-BFGS, $\alpha = 10^{-2}$	F1 = 0,909 $\pm$ 0,033
MLP regressor	2 camadas ocultas (64 e 32 neurônios), tanh, L-BFGS, $\alpha = 10^{-2}$	RMSE = 1,94 $\pm$ 0,39

Algumas escolhas divergem do que a análise de sensibilidade sugeria isoladamente. No classificador RF, usar um único atributo por divisão foi a melhor opção na configuração base, mas a busca em grade preferiu os três atributos, em combinação com a entropia e os pesos balanceados. No classificador MLP, a camada única de 16 neurônios foi a pior arquitetura na configuração base e, ainda assim, venceu quando combinada com o L-BFGS e a tanh. Isso mostra que os hiperparâmetros interagem entre si, e que o efeito de um depende dos valores dos demais.

4.3. Desempenho no conjunto de teste

A Tabela 3 reúne as métricas dos quatro modelos no conjunto de teste. Para os regressores, as métricas de classificação se referem à classe obtida pelos limites de gravidade.

Tabela 3. Desempenho no conjunto de teste. Precisão, revocação e F1 são médias macro. Rev. crítico e Rev. estável são as revocações das classes 1 e 4. Em negrito, o melhor valor de cada coluna.

Modelo	Acurácia	Precisão	Revocação	F1	Rev. crítico	Rev. estável	RMSE
RF classificador	0,910	0,929	0,811	0,848	0,957	0,500	–
RF regressor	0,947	**0,964**	0,909	0,934	0,894	**0,833**	2,40
MLP classificador	0,930	0,900	0,856	0,876	0,894	0,667	–
MLP regressor	**0,960**	0,962	**0,932**	**0,944**	**0,979**	**0,833**	**2,13**

O resultado mais consistente é a vantagem da classificação obtida a partir da gravidade. Nas duas técnicas, o regressor seguido dos limites superou o classificador direto em F1 macro, de 0,848 para 0,934 na Random Forest e de 0,876 para 0,944 na MLP. O MLP regressor foi o melhor modelo em quase todas as métricas, com acurácia de 0,960, menor RMSE (2,13, com MAE de 1,24 e R^2 de 0,983, contra 1,50 e 0,978 do RF regressor) e apenas uma vítima crítica classificada incorretamente entre 47. Os valores no teste ficaram próximos dos obtidos na validação cruzada, dentro de cerca de um desvio padrão.

Na revocação da classe crítica, a ordem dos modelos muda. O RF classificador, com o pior F1 macro, identificou 45 das 47 vítimas críticas, enquanto o RF regressor e o MLP classificador identificaram 42. No RF classificador, a diferença entre a precisão (0,929) e a revocação (0,811) vem principalmente das classes 3 e 4: ele deixou de reconhecer 13 vítimas potencialmente estáveis, classificadas como instáveis, e metade das estáveis. Na classe estável, com apenas 6 vítimas no teste, a revocação variou de 0,50 a 0,83, ou seja, de três a cinco acertos.

As matrizes de confusão (Figura 2) mostram que todos os erros, nos quatro modelos, ocorreram entre classes vizinhas. Nenhuma vítima crítica foi classificada como potencialmente estável ou estável. A Figura 3 mostra que, nos regressores, os erros de classe (16 na Random Forest e 12 na MLP) se concentram perto dos limites de 25, 50 e 75, onde um erro pequeno de gravidade basta para mudar a classe prevista.

Quanto à importância dos atributos, os três se mostraram relevantes em todos os modelos, com pesos relativos entre 29% e 40%. O padrão de importância dependeu mais da tarefa do que da técnica: os dois classificadores atribuíram maior peso à qPA, enquanto os dois regressores atribuíram maior peso à frequência respiratória.

5. Comparação entre as modelagens

5.1. Semelhanças

As duas modelagens alcançaram desempenho alto e de mesma ordem, com acurácia entre 0,91 e 0,96 no teste. Em ambas, todos os erros ocorreram entre classes vizinhas, e nenhuma vítima crítica foi confundida com uma estável. Esse comportamento é desejável na triagem, pois um erro entre faixas adjacentes tem consequência clínica menos severa do que um erro entre extremos.

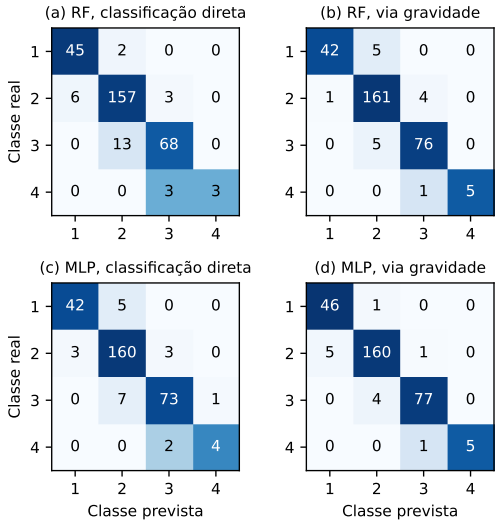


Figura 2. Matrizes de confusão no conjunto de teste. A cor indica a proporção de cada classe real atribuída a cada classe prevista.

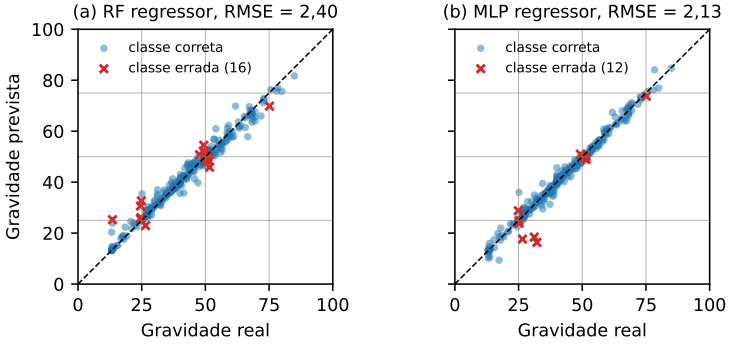


Figura 3. Gravidade real e prevista pelos regressores no conjunto de teste. Os pontos em vermelho tiveram a classe obtida pelos limites diferente da classe real. As linhas cinzas marcam os limites entre as classes.

As duas técnicas também se beneficiaram da mesma estratégia: prever a gravidade e derivar a classe pelos limites foi melhor do que classificar diretamente. Uma explicação é a natureza das classes. Elas são faixas ordenadas de uma grandeza contínua, mas um classificador as trata como categorias independentes e precisa aprender as fronteiras entre elas apenas a partir dos rótulos. O regressor, ao contrário, aprende a própria gravidade, e cada exemplo informa não só a classe da vítima, mas também o quão perto ela está de uma fronteira. Isso pesa na classe estável, que tem só 24 exemplos de treino: o classificador depende desses poucos exemplos, enquanto o regressor aproveita todas as vítimas para modelar a gravidade.

5.2. Diferenças

A MLP superou a Random Forest nas duas tarefas: na classificação direta (F1 macro de 0,876 contra 0,848), na classificação via gravidade (0,944 contra 0,934) e na regressão (RMSE de 2,13 contra 2,40). A diferença é mais clara na regressão, em que a vantagem da MLP também apareceu na validação cruzada (RMSE de 1,94 contra 2,79), bem acima da variação entre as partições. Uma explicação plausível está na forma como cada modelo representa a função. A gravidade varia de forma contínua com os sinais vitais (Figura 1). Uma rede neural produz naturalmente uma função contínua, enquanto uma floresta produz uma função em degraus, formada pela média de regiões

constantes definidas pelos limiares das árvores. Com 1200 exemplos de treino, esses degraus aproximam bem a função, mas não tão bem quanto a rede.

Na classificação, porém, a diferença é pequena. Na validação cruzada, ela é menor que o desvio padrão entre as partições (0,909 contra 0,881, com desvios de cerca de 0,035), e no teste corresponde a seis vítimas entre 300 na classificação direta e a quatro na classificação via gravidade.

5.3. Vantagens e limites de cada modelagem

A Random Forest, representante do paradigma simbólico, exigiu menos cuidados de preparação: não depende da escala dos atributos, oferece pesos por classe e mostrou resultados estáveis entre execuções. Sua principal vantagem é a interpretabilidade, ainda que parcial: cada árvore é um conjunto de regras sobre os sinais vitais, e é possível rastrear o caminho de uma decisão. Por outro lado, uma floresta com 100 ou 300 árvores de profundidade ilimitada não é legível como um todo, e sua saída em degraus limitou a precisão na regressão.

A MLP, representante do paradigma conexionista, obteve os melhores resultados, mas com mais exigências e menos transparência. Ela depende da padronização das entradas, tem mais hiperparâmetros que interagem entre si e é sensível a detalhes da execução: as melhores configurações ficaram tão próximas que diferenças de ambiente de execução, entre computadores, mudaram a configuração vencedora, e o L-BFGS exigiu decidir um limite de iterações. Além disso, o conhecimento da rede fica distribuído nos pesos, sem uma explicação direta de por que uma vítima recebeu determinada classe, o que é uma limitação relevante num cenário de triagem, discutido na Seção 6.

5.4. Limites do estudo

Algumas limitações valem para as duas modelagens. Os dados são sintéticos e foram gerados por uma fórmula fixa, sem o ruído de medição e a variação entre pessoas de um cenário real, de modo que o desempenho obtido não deve ser tomado como estimativa para vítimas reais. O conjunto de teste tem 300 vítimas, e a classe estável, apenas 6, o que torna incertas as métricas dessa classe e faz com que parte das diferenças entre os modelos corresponda a poucas vítimas. Por fim, os resultados vêm de uma única divisão entre treino e teste, o que não permite verificar se as diferenças entre as técnicas são estatisticamente significativas.

6. Desdobramentos em cenários com pessoas

Aplicar aprendizado de máquina à triagem de vítimas significa transferir a um sistema automatizado parte de uma decisão que afeta diretamente a vida das pessoas. Esta seção discute o que mudaria se uma das modelagens fosse de fato usada nesse contexto.

Ética e responsabilidade. Um sistema de triagem erra, e os erros não têm o mesmo peso. Classificar uma vítima crítica como instável pode atrasar um atendimento urgente, enquanto o erro contrário consome recursos que fariam falta a outra pessoa. Para ilustrar a escala, vamos considerar um desastre com 1000 vítimas e a mesma proporção de críticos dos dados (cerca de 156). Com a revocação crítica do MLP regressor (0,979), cerca de 3 vítimas críticas deixariam de ser identificadas. Com a do RF regressor ou do MLP classificador (0,894), seriam cerca de 16. Essa diferença mostra que a escolha do critério de avaliação já é uma decisão ética. Neste trabalho, o F1 macro deu o mesmo peso às quatro classes, mas uma equipe médica poderia preferir priorizar a revocação da classe crítica, aceitando mais erros nas demais. Essa escolha não deveria caber apenas a quem desenvolve o sistema. Há ainda a questão da responsabilidade. Quando uma decisão automatizada contribui para um desfecho trágico, não é evidente sobre quem ela recai: o

profissional que seguiu a recomendação, a equipe que desenvolveu o modelo ou a instituição que o adotou. A falta de uma resposta clara para essa pergunta é, por si só, um motivo de cautela.

Justiça. Um modelo aprende o que é "normal" a partir dos dados que recebe. Nos dados deste trabalho, a gravidade é máxima com pulso entre 60 e 100 e respiração entre 12 e 16, faixas típicas de um adulto em repouso. Mas existem grupos para os quais essas faixas não valem: bebês têm pulso normal acima de 100, atletas costumam ter pulso de repouso abaixo de 60, e certos medicamentos alteram os sinais vitais. Para essas pessoas, o modelo tenderia a atribuir uma gravidade sistematicamente errada, e o desfavorecimento não viria de uma intenção, mas da composição dos dados. O mesmo mecanismo aparece nos resultados com a classe estável, a menos representada e a de menor revocação em todos os modelos. Nesse aspecto, a Random Forest oferece um recurso que a MLP da biblioteca não oferece: os pesos por classe, que permitem compensar grupos sub-representados. Ainda assim, nenhuma técnica corrige a ausência de um grupo nos dados. De forma mais geral, nenhum modelo é neutro: ele carrega os vieses presentes nos dados e nas escolhas de quem o desenvolveu, como os atributos usados e a métrica otimizada.

Confiança no sistema. Uma acurácia de 96% pode gerar confiança excessiva, levando socorristas a aceitar a classificação sem questioná-la, risco que aumenta sob a pressão e a falta de tempo de uma catástrofe. A forma de construir uma confiança adequada difere entre as modelagens. Na Random Forest, é possível mostrar quais sinais pesaram na decisão e seguir o caminho das árvores, o que permite ao profissional conferir se a justificativa faz sentido clínico. Na MLP, a confiança precisa se apoiar quase inteiramente no histórico de desempenho, já que a rede não oferece uma explicação direta. A sensibilidade da MLP ao ambiente de execução, observada neste trabalho, também dificulta auditorias. Um modelo um pouco menos preciso, mas explicável e reprodutível, pode ser preferível quando a decisão precisa ser justificada.

Controle humano. Nos dois casos, o sistema deveria funcionar como apoio à decisão, com a palavra final de um profissional e a possibilidade de contestar a classificação. Como os erros de classe dos regressores se concentram perto dos limites entre as faixas, o sistema poderia exibir a gravidade estimada, e não só a classe, e sinalizar para reavaliação humana as vítimas cuja gravidade prevista estivesse próxima de um limite, por exemplo a menos de um RMSE de distância, dirigindo a atenção humana aos casos em que o modelo é menos confiável.

Trabalho e relações pessoais. Um sistema assim poderia acelerar a triagem, mas seu uso contínuo pode enfraquecer a prática da avaliação clínica, tornando a equipe dependente da ferramenta justamente quando ela falha. Para uma vítima ou sua família, ouvir que a prioridade foi definida por um algoritmo pode soar impessoal ou injusto, sobretudo se ninguém consegue explicar por quê, e a explicabilidade, novamente mais acessível na Random Forest, ajuda a manter a comunicação entre as pessoas no centro do atendimento.

Privacidade. Sinais vitais são dados de saúde e, portanto, dados pessoais sensíveis segundo a Lei Geral de Proteção de Dados (Lei n.º 13.709/2018). Os modelos deste trabalho usam apenas três sinais, sem nenhuma identificação da vítima, o que segue o princípio de usar somente os dados necessários.

7. Conclusão

Este trabalho comparou duas técnicas de aprendizado de máquina, a Floresta Aleatória (Random Forest), de base simbólica, e a rede neural MLP, de base conexionista, aplicadas à avaliação da gravidade de vítimas a partir de três sinais vitais. Cada técnica foi usada de duas formas: para estimar o valor da gravidade (regressão) e para indicar a classe de gravidade (classificação).

As duas técnicas funcionaram bem no problema, com F1 macro sempre acima de 0,84 e erros apenas entre classes vizinhas. O resultado mais consistente foi a vantagem de prever a gravidade e derivar a classe pelos limites, que superou a classificação direta nas duas técnicas e se explica pela natureza ordenada das classes. Nessa abordagem, o melhor modelo foi a MLP regressora, que estimou a gravidade com RMSE de 2,13 e R^2 de 0,98 e, ao converter a gravidade estimada em classe, alcançou 0,96 de acurácia e 0,94 de F1 macro. A Random Forest ficou logo atrás, com RMSE de 2,40 e F1 macro de 0,93.

Ainda assim, nenhuma das técnicas pode ser apontada como melhor em tudo. A MLP oferece um pouco mais de precisão neste problema, enquanto a Random Forest é mais simples de preparar, mais estável entre execuções e mais fácil de interpretar, o que importa quando a decisão afeta diretamente pessoas (Seção 6). O melhor modelo também muda conforme o critério: na revocação da classe crítica, a métrica de maior peso em uma triagem real, o classificador baseado em Random Forest ficou à frente de modelos com F1 macro maior. A escolha entre as técnicas depende do que se valoriza em cada situação. Em qualquer caso, um sistema como esse deve servir de apoio ao profissional, e não de substituto.

Trabalhos futuros podem superar as limitações discutidas na Seção 5, repetindo o experimento com várias divisões dos dados, adotando critérios de escolha que priorizem a classe crítica e, principalmente, validando os modelos com dados reais, que incluam a variação fisiológica entre diferentes grupos de pessoas.

8. Divisão de Trabalho e Carga Horária

O desenvolvimento deste projeto ocorreu de forma integralmente colaborativa entre Felipe dos Reis Garcez e Gabriel Affonso Borges Caballero. Ambos participaram de todas as etapas, com Gabriel concentrando-se na modelagem com Random Forest e Felipe na modelagem com MLP. Cada integrante dedicou 15 horas ao trabalho, totalizando 30 horas de esforço conjunto, distribuídas igualmente nas seguintes frentes:

- **Fundamentação e modelagem (5 horas por pessoa):** revisão teórica de florestas aleatórias e redes neurais, análise exploratória dos dados e definição da modelagem do problema.
- **Desenvolvimento computacional (5 horas por pessoa):** implementação do pipeline de pré-processamento, dos modelos Random Forest e MLP e dos experimentos de seleção de hiperparâmetros.
- **Avaliação e documentação (5 horas por pessoa):** definição da metodologia de avaliação, geração das métricas e figuras e redação do artigo.

Referências

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088):533–536.

A. Grades de hiperparâmetros

A Tabela 4 lista os valores testados na busca em grade. Na MLP, a taxa de aprendizado só se aplica ao otimizador Adam, por isso a busca foi dividida em duas grades, uma por otimizador. Em todas as redes, o limite de iterações foi fixado em 1000.

Tabela 4. Valores testados na busca em grade de cada modelo.

Modelo	Hiperparâmetro	Valores testados
RF classificador	Número de árvores	100, 300
(64 configurações)	Critério de divisão	Gini, entropia
	Profundidade máxima	10, ilimitada
	Mínimo para divisão	2, 5
	Atributos por divisão	1, 3
	Peso das classes	nenhum, balanceado
RF regressor	Número de árvores	100, 300
(16 configurações)	Profundidade máxima	10, ilimitada
	Mínimo para divisão	2, 5
	Atributos por divisão	1, 3
	Critério de divisão	erro quadrático (fixo)
MLP classificador e	Camadas ocultas	(16), (32, 16), (64, 32)
MLP regressor	Ativação	ReLU, tanh
(48 configurações cada)	Regularização (α)	10^{-4}, 10^{-2}
	Otimizador	Adam, L-BFGS
	Taxa de aprendizado	10^{-1}, 10^{-2}, 10^{-3} (só no Adam)

B. Análise de sensibilidade

As Tabelas 5 e 6 mostram o efeito isolado de cada hiperparâmetro. Partindo de uma configuração base, apenas um hiperparâmetro foi variado por vez, e cada variação foi avaliada pela mesma validação cruzada de cinco partições usada na busca em grade. Para a classificação, valores maiores de F1 macro são melhores. Para a regressão, valores menores de RMSE são melhores.

Em alguns casos, como a rede com três camadas ocultas e a regularização de 10^{-1} na MLP, o melhor valor da análise ficou fora da grade, mas com vantagem dentro do desvio padrão entre as partições. Como os hiperparâmetros interagem entre si, porém, não se pode descartar que esses valores tivessem um desempenho melhor em combinação com os demais hiperparâmetros escolhidos.

Tabela 5. Análise de sensibilidade da Random Forest (média ± desvio padrão na validação cruzada). Configuração base: 100 árvores, critério de Gini, profundidade ilimitada, mínimo de 2 exemplos para divisão, 1 atributo por divisão e sem pesos por classe. Em negrito, o melhor valor de cada hiperparâmetro.

Hiperparâmetro	Valor	Classificação (F1 macro)	Regressão (RMSE)
Número de árvores	10	0,815 ± 0,052	5,02 ± 0,65
	50	0,841 ± 0,022	4,28 ± 0,51
	100	**0,854 ± 0,023**	4,20 ± 0,58
	300	0,843 ± 0,028	4,13 ± 0,53
	500	0,844 ± 0,024	**4,11 ± 0,51**
Profundidade máxima	3	0,464 ± 0,037	10,02 ± 0,62
	5	0,612 ± 0,024	7,44 ± 0,62
	10	0,836 ± 0,031	4,57 ± 0,53
	20	**0,854 ± 0,023**	**4,19 ± 0,58**
	ilimitada	**0,854 ± 0,023**	4,20 ± 0,58
Mínimo para divisão	2	**0,854 ± 0,023**	**4,20 ± 0,58**
	5	0,840 ± 0,023	4,38 ± 0,50
	10	0,813 ± 0,033	5,00 ± 0,52
	20	0,752 ± 0,030	5,80 ± 0,51
Atributos por divisão	1	**0,854 ± 0,023**	4,20 ± 0,58
	2	0,843 ± 0,033	3,08 ± 0,53
	3	0,838 ± 0,034	**2,83 ± 0,46**
Critério de divisão	Gini	**0,854 ± 0,023**	–
	entropia	0,845 ± 0,029	–
Peso das classes	nenhum	0,854 ± 0,023	–
	balanceado	**0,855 ± 0,035**	–

Tabela 6. Análise de sensibilidade da MLP (média ± desvio padrão na validação cruzada). Configuração base: camadas ocultas de 32 e 16 neurônios, ReLU, Adam, taxa de aprendizado de 10^{-3}, $\alpha = 10^{-4}$ e limite de 1000 iterações. Em negrito, o melhor valor de cada hiperparâmetro.

Hiperparâmetro	Valor	Classificação (F1 macro)	Regressão (RMSE)
Camadas ocultas	16	0,782 ± 0,041	11,12 ± 1,50
	32	0,842 ± 0,021	8,41 ± 0,74
	32 e 16	0,847 ± 0,032	4,29 ± 0,54
	64 e 32	0,871 ± 0,022	**2,77 ± 0,23**
	64, 32 e 16	**0,885 ± 0,032**	2,80 ± 0,19
Taxa de aprendizado	10^{-1}	0,822 ± 0,040	4,09 ± 0,67
	10^{-2}	**0,878 ± 0,034**	**3,52 ± 0,32**
	10^{-3}	0,847 ± 0,032	4,29 ± 0,54
	10^{-4}	0,529 ± 0,022	17,55 ± 0,81
Regularização (α)	10^{-5}	0,863 ± 0,020	4,23 ± 0,74
	10^{-4}	0,847 ± 0,032	4,29 ± 0,54
	10^{-3}	0,860 ± 0,019	4,30 ± 0,57
	10^{-2}	0,863 ± 0,012	4,28 ± 0,44
	10^{-1}	**0,872 ± 0,033**	**4,17 ± 0,36**
Ativação	ReLU	0,847 ± 0,032	**4,29 ± 0,54**
	tanh	**0,893 ± 0,033**	6,54 ± 0,54
	logística	0,612 ± 0,028	14,79 ± 0,60
Otimizador	Adam	0,847 ± 0,032	4,29 ± 0,54
	L-BFGS	**0,899 ± 0,020**	**2,26 ± 0,13**
	SGD	0,555 ± 0,013	3,84 ± 0,42